



UNIVERSITÀ DEGLI STUDI DI UDINE
COMUNICAZIONE MULTIMEDIALE E TECNOLOGIE DELL'INFORMAZIONE

Tecniche di Deep Learning per il rilevamento di anomalie nelle immagini

Relatore: Prof. Gian Luca Foresti


Laureando: Riccardo Verk

Anno accademico 2018/19

Definizione del problema

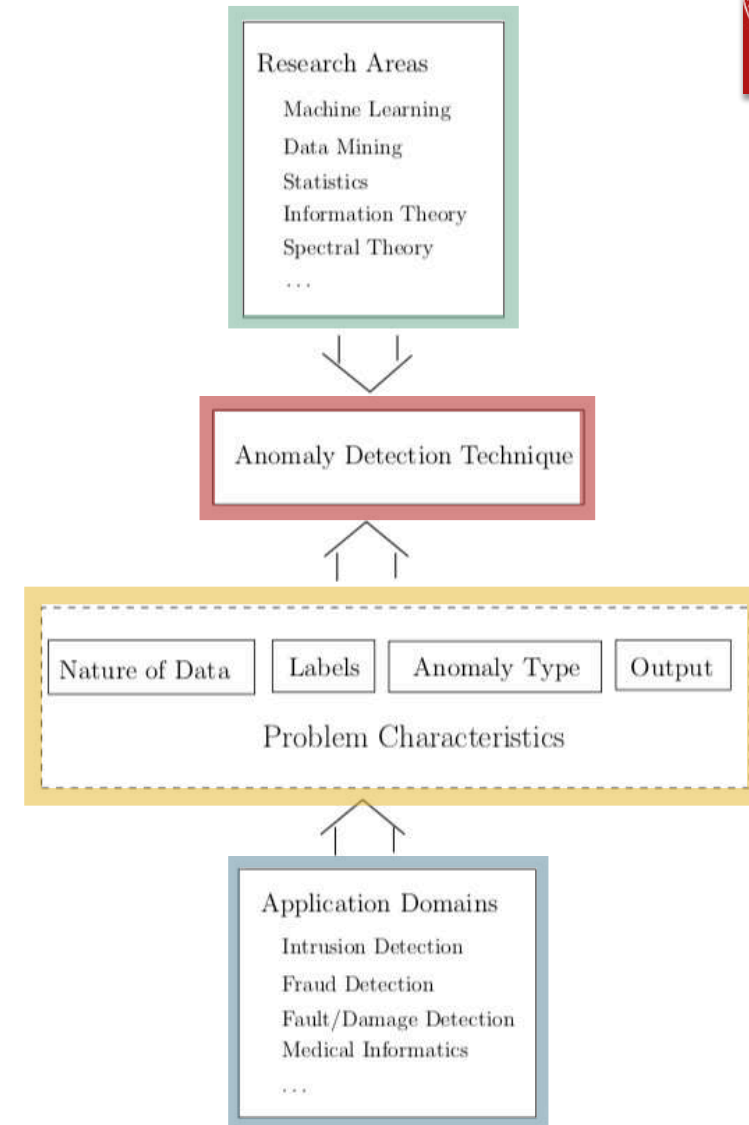


- ▶ Rilevamento di possibili anomalie in immagini attraverso tecniche di Deep Learning




Anomaly Detection

- È una tecnica utilizzata per l'identificazione di elementi, eventi o osservazioni anomale che si differenziano in modo significativo dalla maggior parte dei dati




Tipi di anomalia


- ▶ **Anomalie puntiformi:** una singola istanza di dati è considerata anomala rispetto al resto dei dati
- ▶ **Anomalie contestuali:** un'istanza di dati è anomala in un contesto specifico (ma non altrove)
- ▶ **Anomalie collettive:** una raccolta di istanze di dati correlati è anomala rispetto all'intero set di dati



Anomalie contestuali

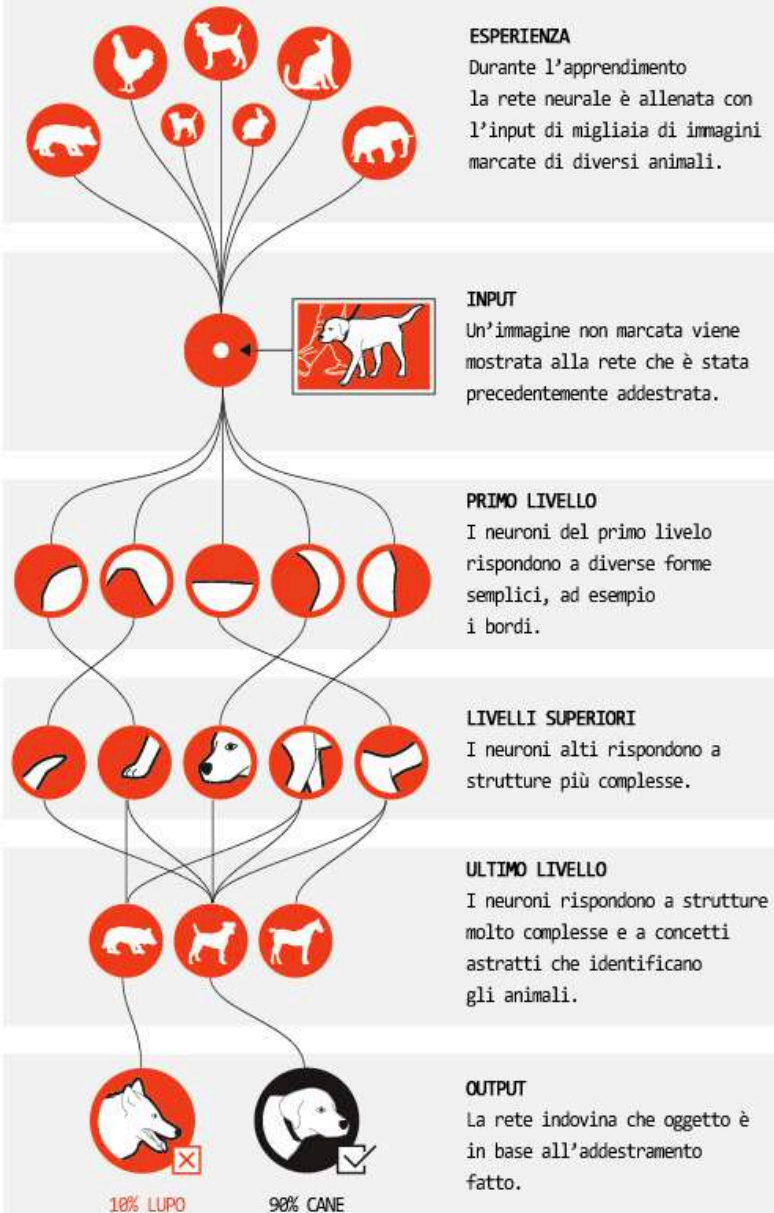


Anomalie puntiformi



Anomalie collettive

COME LE RETI NEURALI RICONOSCONO LA FOTO DI UN CANE



Il Deep Learning

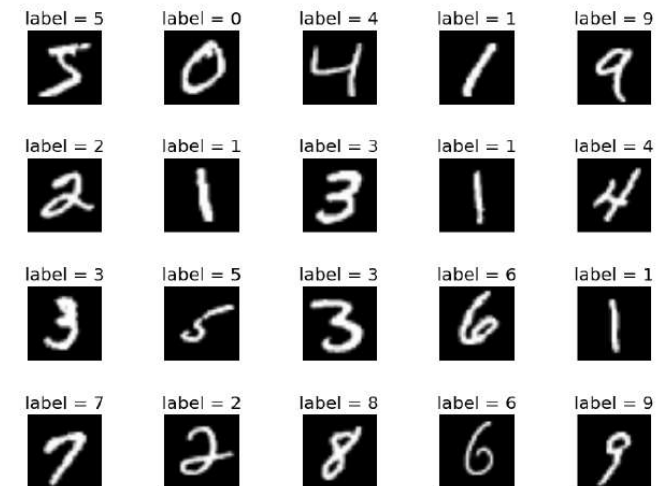
- ▶ È definito come una classe di algoritmi di apprendimento automatico
- ▶ Usa vari livelli di unità non lineari a cascata per svolgere compiti di estrazione di caratteristiche e di trasformazione
- ▶ Le caratteristiche di livello più alto vengono derivate da quelle di livello più basso per creare una rappresentazione gerarchica
- ▶ Apprendono più livelli di rappresentazione che corrispondono a differenti livelli di astrazione
- ▶ L'output di una rete è di solito una label che indovina l'oggetto di input



Label dei dati nel caso dell'Anomaly Detection



- ▶ Le label associate ad un'istanza di dati indicano se tale istanza è normale o anomala
- ▶ **Problemi:** ottenere le label dei dati che siano accurate e rappresentative di tutti i tipi di comportamento è spesso proibitivo
- ▶ Il labeling è spesso eseguito **manualmente** da esperti umani e richiede quindi un notevole sforzo per ottenere i dati di training etichettati




Apprendimento di una rete di Deep Learning

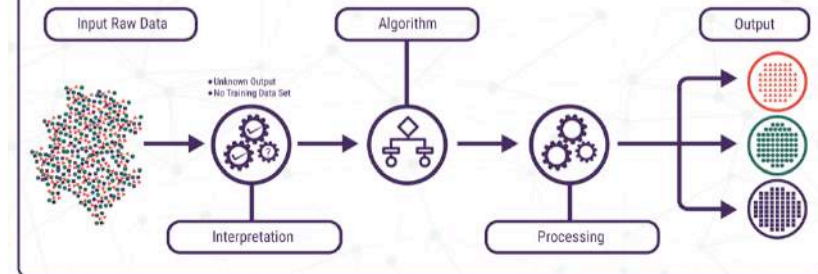
► In base alla disponibilità delle label, le tecniche di rilevamento delle anomalie possono operare in una delle tre modalità seguenti:

1. Supervised anomaly detection
2. Unsupervised anomaly detection
3. Semi-Supervised anomaly detection

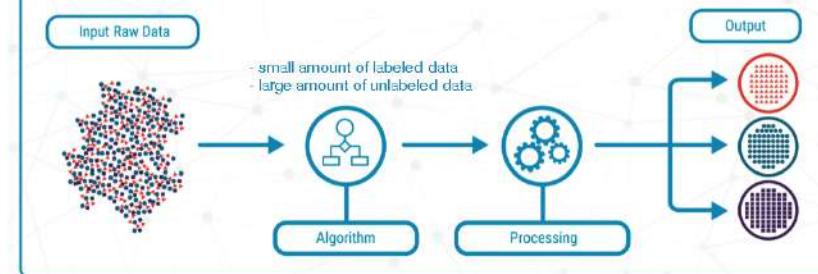
SUPERVISED LEARNING



UNSUPERVISED LEARNING



SEMI-SUPERVISED LEARNING







Tecniche statistiche per l'Anomaly Detection


Tecniche di rilevazione delle anomalie basate sulla classificazione (Approccio supervisionato)



- ▶ La classificazione è usata per addestrare un modello (classificatore) da un insieme di istanze di dati etichettati (training) e poi, classificare un'istanza di test in una delle classi usando il modello appreso (testing)
- ▶ Possono essere raggruppate in due grandi categorie:
 - ▶ One-class anomaly detection
 - ▶ Multi-class anomaly detection



Tecniche di rilevamento delle anomalie basate sulla densità (Approccio non supervisionato)

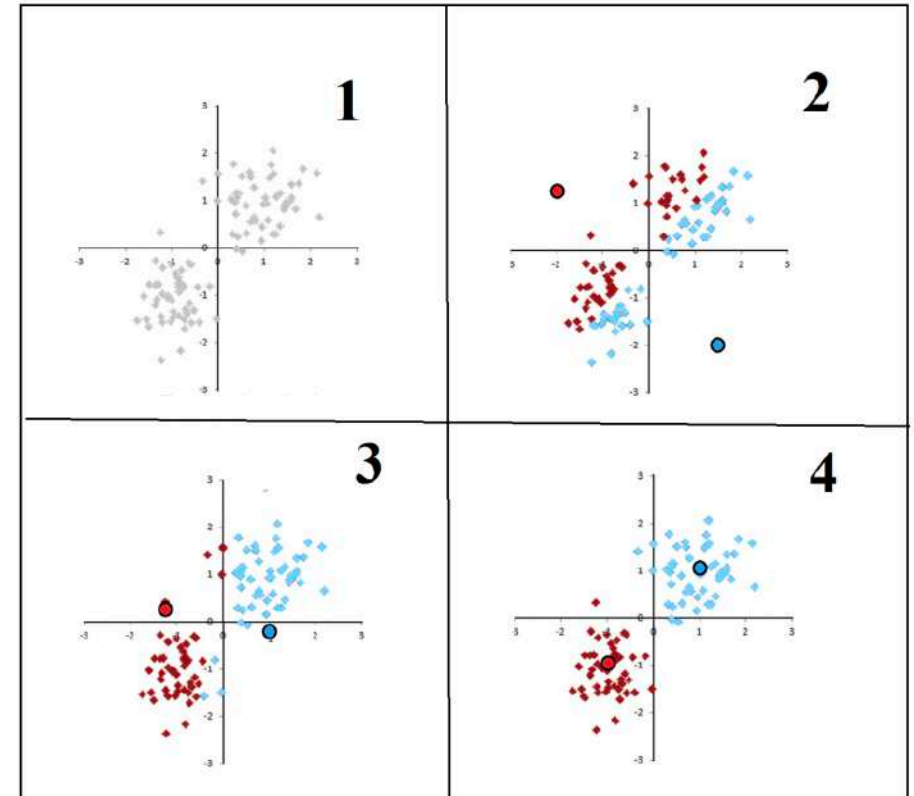


- ▶ Il rilevamento delle anomalie basato sulla densità si basa sull'algoritmo KNN (K-Nearest Neighbors)
- ▶ I dati normali si presentano in un insieme denso, mentre le anomalie sono lontane
- ▶ L'insieme più vicino di dati viene valutato utilizzando un punteggio, che si basa su una distanza (es. euclinese)

Tecniche di rilevamento delle anomalie basate sul clustering (Approccio non supervisionato)




- ▶ Il **clustering** è uno dei concetti più popolari nel campo dell'apprendimento non supervisionato
- ▶ I dati simili in uno spazio di n dimensioni tendono ad appartenere a gruppi simili, in base alla media aritmetica delle loro posizioni (centroide)
- ▶ Il clustering è usato per raggruppare istanze di dati simili in gruppi
- ▶ Un algoritmo ampiamente usato è il **K-mean**:
 - ▶ Crea 'k' gruppi simili di dati in uno spazio
 - ▶ Le istanze di dati che non rientrano in questi gruppi potrebbero essere potenzialmente contrassegnate come anomalie.




Problemi aperti



- ▶ Le tecniche viste in precedenza si basano su metodi statistici, e quindi hanno bisogno di parametri pre-impostati per poter addestrare il modello ad estrarre determinate feature
- ▶ La soluzione proposta invece, sfrutta un tipo di rete neurale e quindi l'estrazione delle feature avviene in modo automatico
- ▶ La tecnica proposta mostra quindi i suoi meriti quando i dati sono complessi e di natura non lineare






Soluzione proposta:
Gli Autoencoder

Autoencoder




- ▶ Sono reti neurali con lo scopo di generare nuovi dati dapprima comprimendoli e, successivamente, ricostruendo l'output sulla base delle informazioni acquisite
- ▶ L'obiettivo dell'Autoencoder è quello di ottenere un apprendimento delle caratteristiche utili per la ricostruzione dell'input




Differenti tipologie di Autoencoder



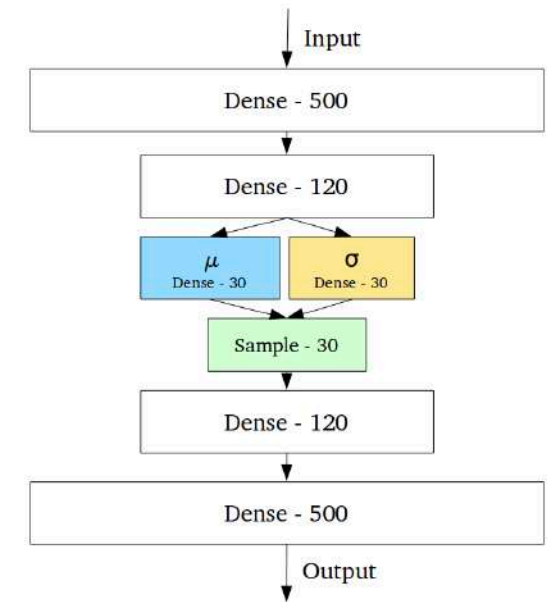
- ▶ **Basic Autoencoder:** (o multilayer) la forma più semplice
- ▶ **Convolutional Autoencoder:** al posto di vettori unidimensionali, vengono utilizzati vettori tridimensionali
- ▶ **Variational Autoencoder:** sono il risultato della combinazione di Deep Learning e inferenza bayesiana, nel senso che sono costituiti da una rete neurale allenata con l'algoritmo di backpropagation modificato con una tecnica chiamata riparametrizzazione



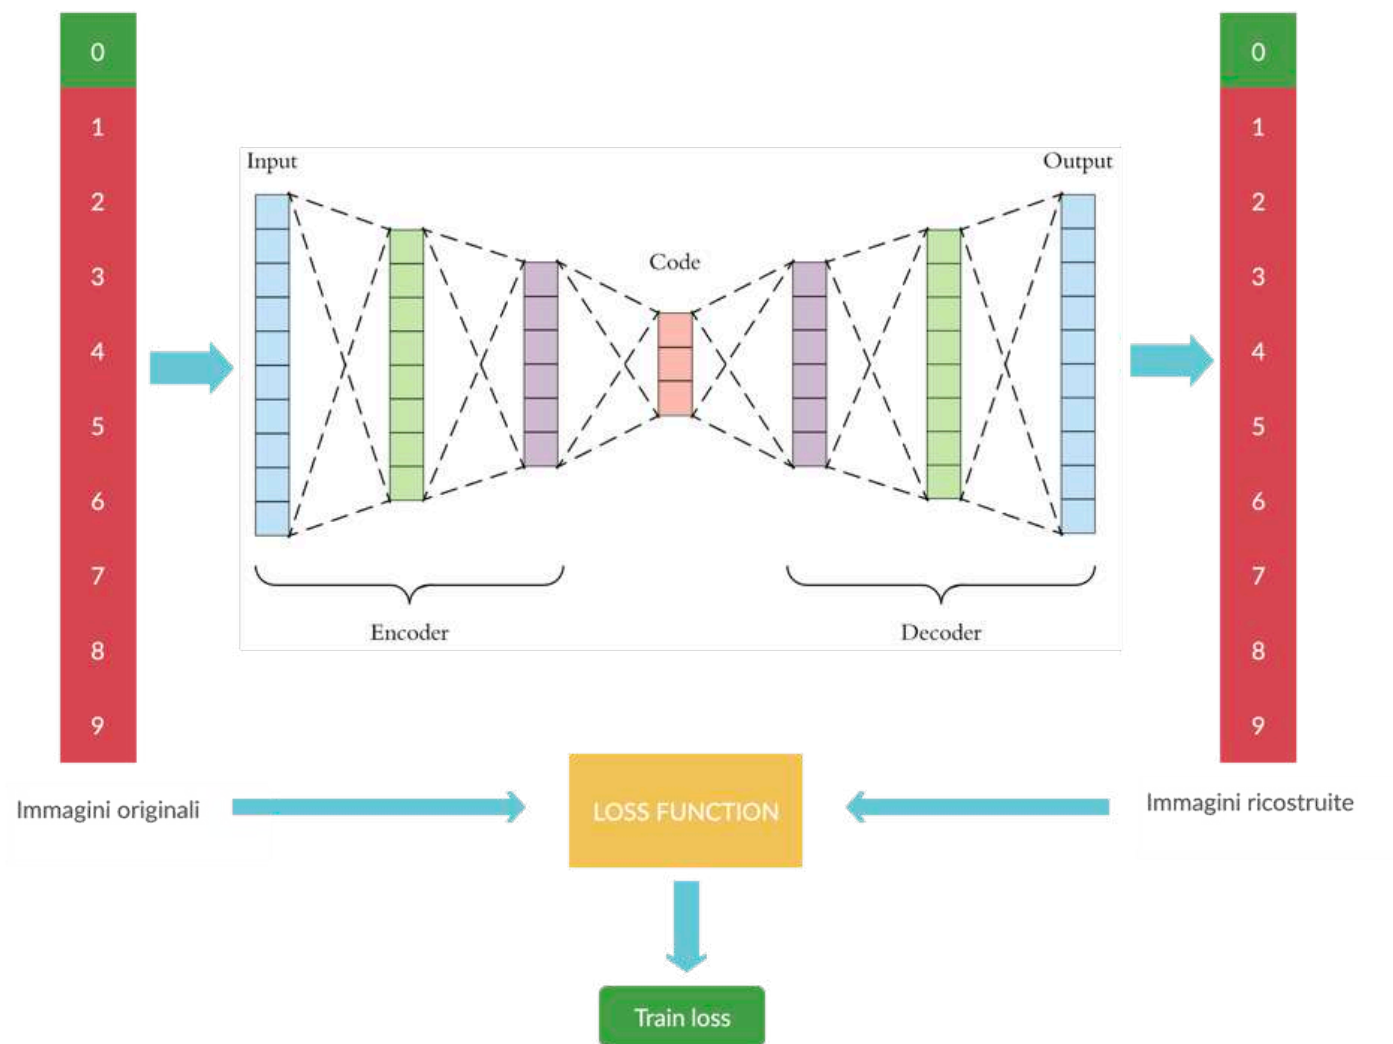
Basic Autoencoder



Convolutional Autoencoder



Variational Autoencoder





Training

Training di un Autoencoder



- ▶ L'apprendimento avviene tramite la minimizzazione della loss function
- ▶ È un metodo per valutare il modo in cui uno specifico algoritmo modella i dati forniti
- ▶ Se le previsioni si discostano troppo dai risultati effettivi, la funzione di perdita potrebbe produrre un numero elevato
- ▶ Con l'aiuto di alcune funzioni di ottimizzazione, la funzione di perdita impara un po' alla volta a ridurre l'errore nella previsione



Loss function prese in considerazione




- ▶ **MSE:** viene misurato come la media della differenza quadrata tra previsioni e osservazioni effettive
- ▶ **BCE:** la perdita aumenta quando la probabilità prevista differisce dall'etichetta effettiva
- ▶ **SSIM:** l'indice di similarità strutturale è un metodo per misurare la somiglianza tra due immagini

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

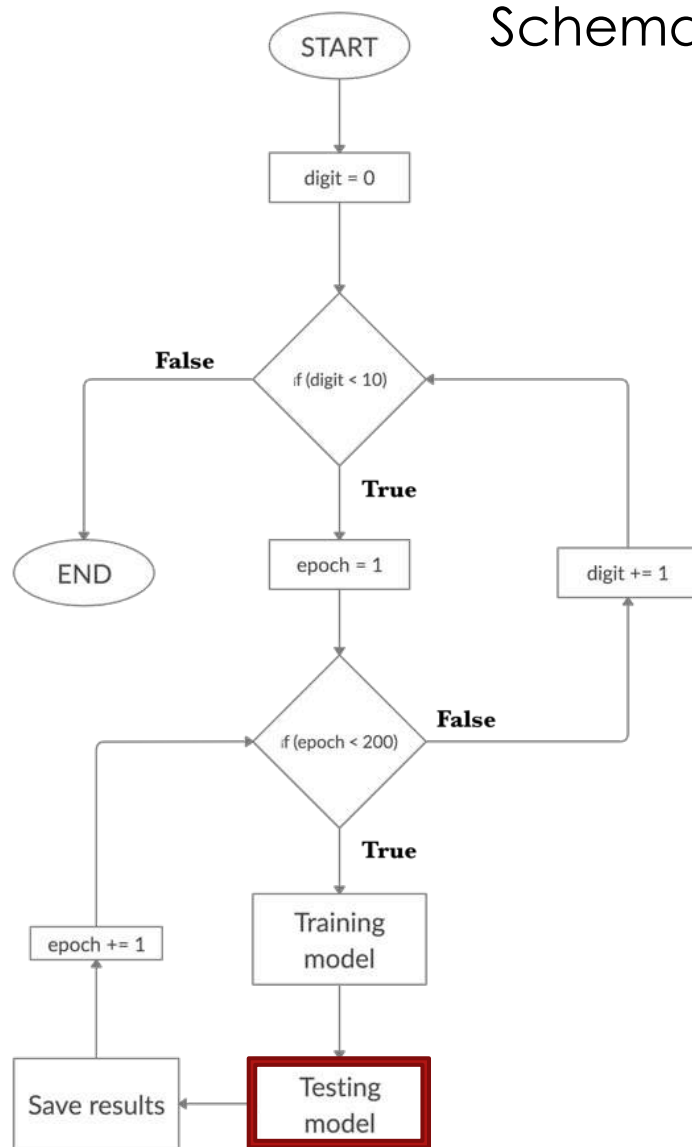
$$\text{BCE} = -\frac{1}{N} \sum_{i=0}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$

$$\text{SSIM}(x, y) = \frac{(2\mu_x \mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}$$

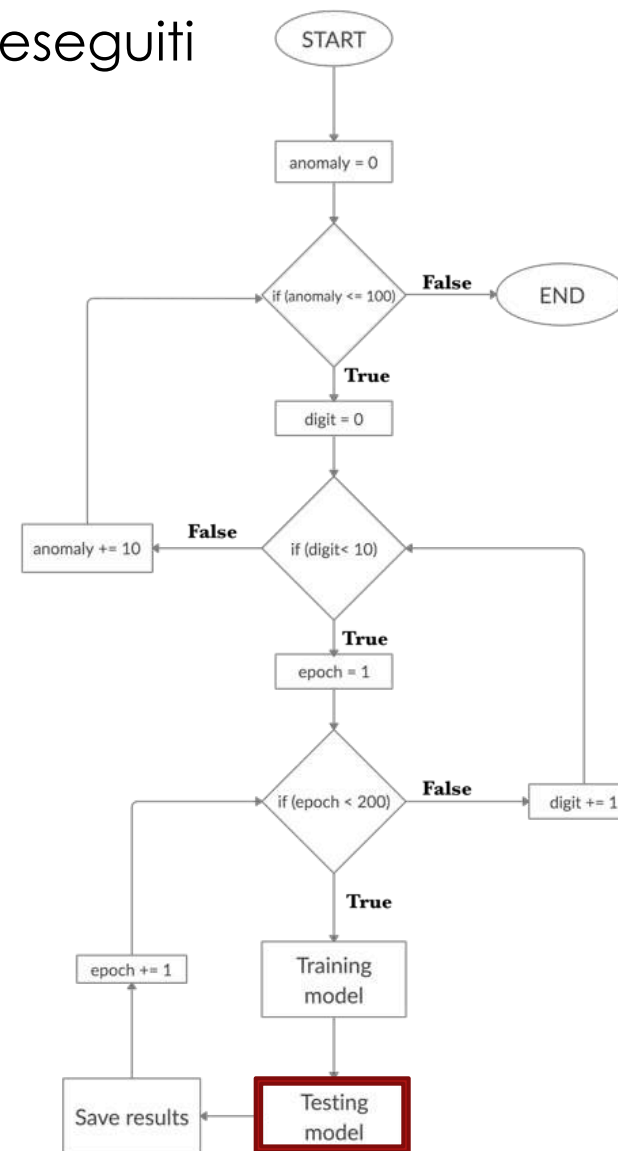


Testing

Schema completo dei test eseguiti



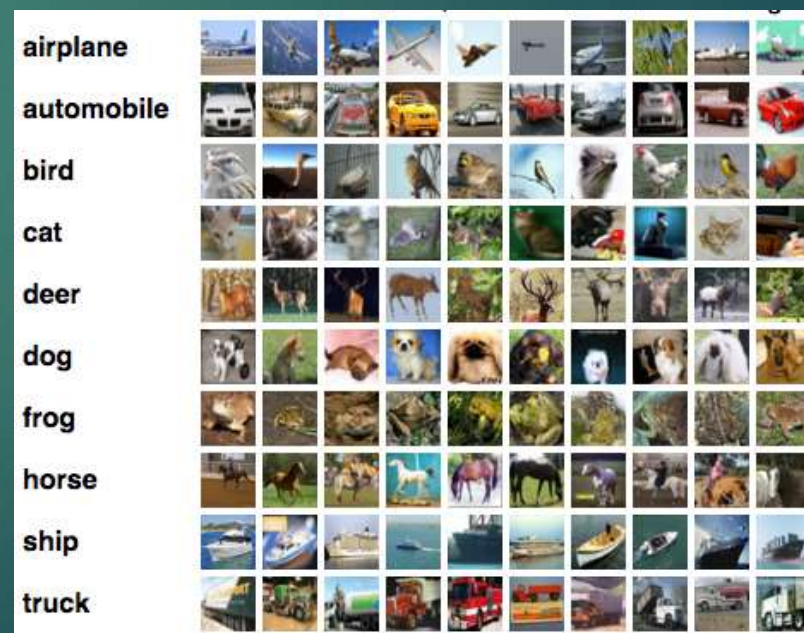
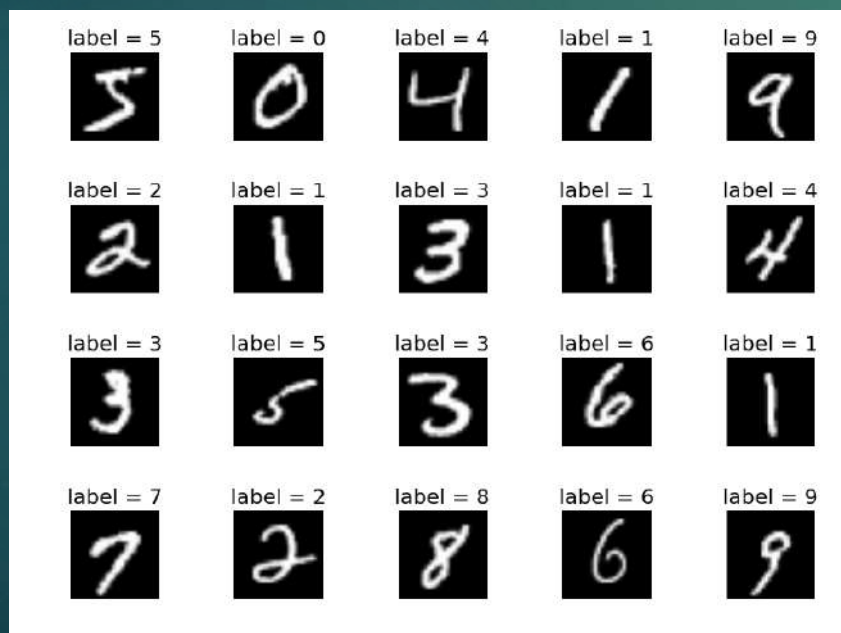
Approccio supervisionato



Approccio non supervisionato

MNIST VS CIFAR10

- ▶ Training set: 60,000 immagini
 - ▶ Testing set: 10,000 immagini
 - ▶ 28x28 in scala di grigi
 - ▶ Classi: 10
- ▶ Training set: 50,000 immagini
 - ▶ Testing set: 10,000 immagini
 - ▶ 32x32 a colori (3 canali RGB)
 - ▶ Classi: 10






Risultati: approccio supervisionato

DATASET MNIST


BASIC AUTOENCODER DIGITS

■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM




CONVOLUTIONAL AUTOENCODER DIGITS

■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM



VARIATIONAL AUTOENCODER DIGITS


■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM



DATASET CIFAR10


BASIC AUTOENCODER DIGITS

■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM




CONVOLUTIONAL AUTOENCODER DIGITS

■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM



VARIATIONAL AUTOENCODER DIGITS

■ BCE ■ BCE + SSIM ■ MSE ■ MSE + SSIM ■ SSIM






Risultati: approccio non supervisionato


DATASET MNIST




Basic autoencoder with anomaly in train dataset



Convolutional autoencoder with anomaly in train dataset




Variational autoencoder with anomaly in train dataset




DATASET CIFAR10



Basic autoencoder with anomaly in train dataset



Convolutional autoencoder with anomaly in train dataset



Variational autoencoder with anomaly in train dataset






Confronto dei migliori risultati ottenuti

DATASET MNIST




DIGIT	AUTOENCODER	LOSS FUNCTION	ACCURACY	AUC
0	BASIC	BCE + SSIM	0,9437	0,9775
1	BASIC	MSE + SSIM	0,9865	0.9975
2	BASIC	BCE + SSIM	0,9267	0,9749
3	VAE	BCE + SSIM	0,8598	0,9103
4	CONVOLUTIONAL	BCE	0,8549	0,9348
5	BASIC	BCE + SSIM	0,8686	0,9176
6	BASIC	BCE + SSIM	0,9530	0,9839
7	BASIC	BCE	0,9410	0,9745
8	BASIC	BCE	0,8272	0,8802
9	CONVOLUTIONAL	BCE + SSIM	0,8916	0,9535
AVG	BASIC	BCE + SSIM	0,8844	0,9346


Model	MNIST									
	Class 0	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Class 8	Class 9
GANomaly [4]	0.881	0.675	0.953	0.801	0.827	0.864	0.849	0.682	0.856	0.558
AnoGAN [3]	0.623	0.31	0.521	0.458	0.442	0.431	0.492	0.401	0.392	0.368
EGBAD [23]	0.783	0.294	0.523	0.506	0.453	0.436	0.593	0.398	0.523	0.358
DenseNet-169	0.998265	0.994258	0.984126	0.980750	0.983918	0.992295	0.984011	0.997476	0.991551	0.999386
ResNet-152	0.998050	0.994176	0.982025	0.981253	0.984338	0.989994	0.980970	0.998940	0.989815	0.998982
Inception-V4	0.997676	0.994609	0.983431	0.980548	0.984617	0.992676	0.983624	0.997108	0.994305	0.999080




classe normale originale





classe normale ricostruita



classe anomala originale




classe anomala ricostruita




DATASET CIFAR10




CLASS	AUTOENCODER	LOSS FUNCTION	ACCURACY	AUC
0	CONVOLUTIONAL	MSE + SSIM	0,7306	0,7714
1	CONVOLUTIONAL	BCE + SSIM	0,4919	0,6093
2	BASIC	MSE	0,7550	0,6116
3	VAE	BCE	0,5188	0,5808
4	VAE	MSE	0,6676	0,7311
5	VAE	MSE + SSIM	0,5326	0,5893
6	VAE	BCE	0,6877	0,7069
7	VAE	BCE	0,5527	0,6104
8	VAE	SSIM	0,7370	0,7757
9	VAE	BCE + SSIM	0,5984	0,6566
AVG	VAE	MSE + SSIM	0,5920	0,5767




classe normale originale





classe normale ricostruita



classe anomala originale



classe anomala ricostruita



Model	CIFAR10									
	plane	car	bird	cat	deer	frog	horse	ship	truck	dog
GANomaly [4]	0.633	0.631	0.51	0.587	0.593	0.683	0.605	0.616	0.617	0.628
AnoGAN [3]	0.516	0.492	0.411	0.399	0.335	0.321	0.399	0.567	0.511	0.393
EGBAD [23]	0.577	0.514	0.383	0.448	0.374	0.353	0.526	0.413	0.555	0.481
DenseNet-169	0.998449	0.998933	0.994980	0.992014	0.998145	0.991758	0.999031	0.998386	0.998948	0.998291
ResNet-152	0.998071	0.998203	0.995249	0.991605	0.998480	0.991375	0.999607	0.999289	0.998934	0.997900
Inception-V4	0.930263	0.971474	0.842340	0.853591	0.895042	0.893674	0.949273	0.921899	0.954804	0.931945

Autoencoder vs DenseNet

- ▶ Gli Autoencoder dei test eseguiti hanno un'architettura con 4-5 livelli, contro i 169 della DenseNet
- ▶ Gli Autoencoder riducono la dimensionalità dei dati, guadagnando così spazio in memoria
- ▶ Inoltre, gli Autoencoder a differenza delle classiche reti neurali, hanno il vantaggio di poter separare l'Encoder dal Decoder

Conclusione e futuri sviluppi



- ▶ In conclusione, possiamo dire che gli Autoencoder possono essere utilizzati nella risoluzione di problemi dell'Anomaly Detection con ottimi risultati
- ▶ In futuro, per ottenere dei risultati ancora più significativi si potrebbe puntare su:
 - ▶ Aumento del numero di livelli della rete
 - ▶ Perfezionamento dei parametri:
 - ▶ Numero di epoche (ampliare lo studio già fatto in questa tesi)
 - ▶ Learning rate
 - ▶ Loss function (ampliare lo studio già fatto in questa tesi)